



PaperPilot

Agentic RAG για Ερευνητικά Άρθρα NLP/LLM

Τσιλιμπώκος Σπυρίδων - 25118

ΠΜΣ Εφαρμογές Επιστήμης των Δεδομένων και Τεχνητής Νοημοσύνης
Ιούνιος 2026



Contents

Αποθετήριο GitHub για κώδικα και πλήρη ανάλυση.....	3
Περίληψη.....	4
1. Εισαγωγή.....	5
1.1 Πρόβλημα.....	5
1.2 Προτεινόμενη Λύση.....	5
1.3 Συνεισφορές.....	5
2. Corpus και Χρυσό Σύνολο Αξιολόγησης.....	6
2.1 Συλλογή Corpus.....	6
2.2 Κατασκευή Χρυσού Συνόλου (Golden Set).....	6
2.3 Σχόλιο για OOC Dilution.....	6
3. Αρχιτεκτονική Συστήματος.....	7
3.1 Επισκόπηση.....	7
3.2 Τεχνολογίες.....	7
3.3 Demo Screenshots.....	7
4. Στρατηγικές Τεμαχισμού (Chunking).....	10
4.1 v1: FixedSize Chunker (512 tokens).....	10
4.2 v2: SectionAware Chunker.....	10
4.3 v3: TableAware Chunker.....	10
5. Αγεντική Ανάκτηση (Agentic RAG).....	11
5.1 Γράφος LangGraph.....	11
5.2 Planner.....	11
5.3 Researcher.....	11
5.4 Ανάκτηση και Reranking.....	11
5.5 Synthesizer.....	11
5.6 Caching.....	11
6. Πλαίσιο Αξιολόγησης.....	12
6.1 RAGAS.....	12
6.2 TCA (Tool Call Accuracy).....	12
6.3 HAIC (Human-AI Collaboration Benchmarking).....	12
7. Αποτελέσματα RAGAS.....	13
7.1 Συνολικά Αποτελέσματα (n=84).....	13
7.2 Context Precision ανά Κατηγορία.....	13
7.3 Context Recall ανά Κατηγορία.....	14
7.4 Faithfulness ανά Κατηγορία.....	15
7.5 Heatmap v3.....	15
7.6 Ανάλυση Αποτελεσμάτων.....	16
8. Αποτελέσματα Tool Call Accuracy (TCA).....	16
8.1 Συνολικά Αποτελέσματα.....	16
8.2 Ανάλυση.....	16
9. Αποτελέσματα HAIC.....	17



9.1 HAIC v1 (4 μετρικές, n=45).....	17
9.2 HAIC v2 (LLM Judge, n=84).....	17
9.3 HAIC v3 (LLM Judge, n=84).....	17
9.4 Ανάλυση HAIC	18
10. Ανάλυση Αποτυχιών	19
10.1 Κύρια Πρότυπα Αποτυχίας	19
Χαμηλή Context Precision σε OOC	19
Χαμηλό Numerical Recall.....	19
Hallucination σε Attribution.....	19
OOC Dilution στα Overall Averages	19
10.2 Σύγκριση Εκδόσεων ανά Πρόβλημα.....	19
11. Περιορισμοί και Μελλοντική Εργασία	20
11.1 Τρέχοντες Περιορισμοί	20
11.2 Μελλοντικές Βελτιώσεις.....	20
11.3 Υλοποιηθείσες Βελτιώσεις Ανάπτυξης (Post-v3)	20
Επιμονή Ιστορικού Συνομιλιών (Thread Persistence).....	20
Μεταφόρτωση PDF και In-Session RAG	20
In-Chat Εναλλαγή Εκδόσεων v1 / v2 / v3.....	20
Επιπλέον Τεχνικές Βελτιώσεις.....	21
12. Συμπεράσματα	21

[Αποθετήριο GitHub για κώδικα και πλήρη ανάλυση](#)



Περίληψη

Η παρούσα εργασία παρουσιάζει το PaperPilot, ένα agentic σύστημα Retrieval-Augmented Generation (RAG) για ακαδημαϊκά άρθρα στους τομείς NLP, LLM και AI Agents. Το σύστημα συνδυάζει τρεις στρατηγικές τεμαχισμού (v1 FixedSize, v2 SectionAware, v3 TableAware), πυκνή ανάκτηση με διανυσματική βάση Qdrant, επαναξιολόγηση με cross-encoder (BGE-reranker-base) και ένα πολυπρακτορικό γράφο LangGraph τριών κόμβων (Planner, Researcher, Synthesizer). Η αξιολόγηση διεξήχθη με τρεις μεθοδολογίες: RAGAS (4 μετρικές), TCA (Tool Call Accuracy) και HAIC (Human-AI Collaboration Benchmarking). Το σύνολο αξιολόγησης αποτελείται από 84 ερωτήσεις σε 6 κατηγορίες, εκ των οποίων 59 εκτός περιεχομένου (Out-Of-Context), δημιουργώντας ένα ρεαλιστικό αλλά απαιτητικό πλαίσιο.



1. Εισαγωγή

1.1 Πρόβλημα

Η επιστημονική κοινότητα παράγει χιλιάδες άρθρα ετησίως στους τομείς της επεξεργασίας φυσικής γλώσσας και των μεγάλων γλωσσικών μοντέλων. Ένας ερευνητής που θέλει να αναζητήσει πληροφορίες για συγκεκριμένες μεθόδους, μετρικές ή σχετικές δημοσιεύσεις αντιμετωπίζει το πρόβλημα της αναζήτησης στο σωστό υποσύνολο, της εξαγωγής σχετικών χωρίων και της σύνθεσης μιας συνεκτικής απάντησης. Τα γενικά LLM δεν γνωρίζουν πρόσφατα άρθρα (κόβουν στο training cut-off) και τείνουν να παράγουν ανακριβείς αναφορές (hallucinations).

1.2 Προτεινόμενη Λύση

Το PaperPilot υλοποιεί ένα pipeline RAG ειδικευμένο σε ακαδημαϊκά άρθρα ArXiv από τους τομείς NLP, LLM, RAG και AI Agents (corpus 2020-2026, περίπου 400 άρθρα). Η αρχιτεκτονική επιλύει το πρόβλημα σε τρία στάδια: (α) ευρετηρίαση με πολλαπλές στρατηγικές τεμαχισμού, (β) αγεντική ανάκτηση μέσω LangGraph και (γ) ολιστική αξιολόγηση με RAGAS, TCA και HAIC.

1.3 Συνεισφορές

- Σύγκριση τριών στρατηγικών τεμαχισμού (FixedSize, SectionAware, TableAware) στο ίδιο corpus.
- Πολυπρακτορικός γράφος LangGraph με ρόλους Planner, Researcher, Synthesizer.
- Σύνολο αξιολόγησης 84 ερωτήσεων σε 6 κατηγορίες με εκτεταμένες OOC ερωτήσεις.
- Εφαρμογή HAIC με LLM-as-judge για αξιολόγηση της συνεργασίας ανθρώπου-AI.
- Streaming UI με Chainlit και επιλογέα εκδόσεων v1/v2/v3.



2. Corpus και Χρυσό Σύνολο Αξιολόγησης

2.1 Συλλογή Corpus

Το corpus αποτελείται από περίπου 400 ακαδημαϊκά άρθρα που λήφθηκαν αυτόματα από το ArXiv μέσω της επίσημης API. Τα άρθρα καλύπτουν τις θεματικές ενότητες: Retrieval-Augmented Generation, Large Language Models, AI Agents, αξιολόγηση NLP συστημάτων και σχετικές μεθοδολογίες. Η χρονική κάλυψη εκτείνεται από το 2020 έως το 2026.

Η διαδικασία συλλογής υλοποιείται στο αρχείο `ingest/arxiv_fetch.py` και περιλαμβάνει αυτόματη λήψη PDF, μετατροπή σε Markdown μέσω `pympdf4llm` (με διατήρηση επικεφαλίδων και πινάκων) και αποθήκευση σε structured format.

2.2 Κατασκευή Χρυσού Συνόλου (Golden Set)

Το χρυσό σύνολο αξιολόγησης (`golden_gen.py`) δημιουργήθηκε με ημι-αυτόματη μεθοδολογία. Χρησιμοποιήθηκε το `gpt-4.1-mini` ως `judge` για την παραγωγή ερωτήσεων και αναμενόμενων εργαλείων ανά κατηγορία. Κάθε ερώτηση συνοδεύεται από metadata: κατηγορία, αναμενόμενο σύνολο εργαλείων (`rag_retrieve` και/ή `arxiv_search`) και `golden answer`.

Πίνακας 1: Κατηγορίες ερωτήσεων χρυσού συνόλου αξιολόγησης.

Κατηγορία	n	Αναμενόμενα Εργαλεία	Περιγραφή
definitional	5	rag_retrieve	Ορισμοί εννοιών (RAG, RAGAS, cross-encoder)
comparative	5	rag_retrieve	Συγκρίσεις μεθόδων (BM25 vs dense, Self-RAG vs RAG)
methodological	5	rag_retrieve	Βηματικές εξηγήσεις (ReAct loop, HyDE generation)
attribution	5	rag_retrieve	Αποδόσεις σε άρθρα (ποιος πρότεινε ReAct, BGE)
numerical	5	rag_retrieve	Αριθμητικά δεδομένα (dim embeddings, param count)
out_of_context	59	rag_retrieve + arxiv_search	Εκτός πεδίου (πολιτική, βιολογία, αθλητισμός)

2.3 Σχόλιο για OOC Dilution

Οι 59 OOC ερωτήσεις (70,2% του συνόλου) αναμένεται να αποδώσουν χαμηλά στις μετρικές RAGAS, καθώς το σύστημα ανακτά άσχετο περιεχόμενο. Αυτό δημιουργεί OOC dilution στα συνολικά averages. Για αυτό η ανάλυση εστιάζει στις in-context κατηγορίες (definitional, comparative, methodological, attribution, numerical) ως πρωταρχικό μέτρο απόδοσης.




3. Αρχιτεκτονική Συστήματος

3.1 Επισκόπηση

Το PaperPilot αναπτύχθηκε ως containerized microservice stack με Docker Compose. Το σύστημα περιλαμβάνει τέσσερις κύριες υπηρεσίες: την εφαρμογή Python (FastAPI + Chainlit), τη βάση διανυσμάτων Qdrant, την πλατφόρμα παρατηρησιμότητας Langfuse και μια PostgreSQL για τα metadata του Langfuse.

Αρχιτεκτονική:

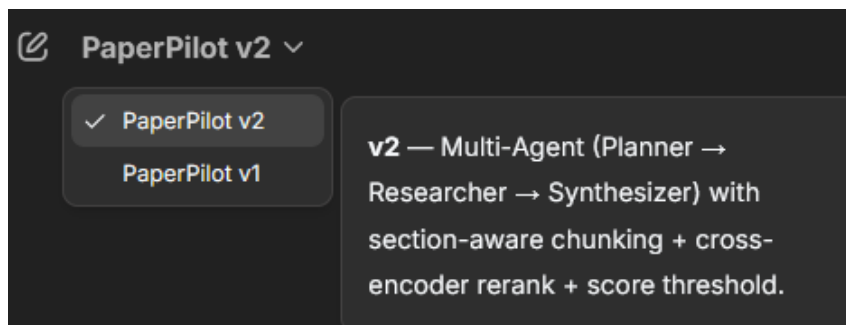


3.2 Τεχνολογίες

Πίνακας 2: Τεχνολογικό στοίβα του PaperPilot ανά στρώμα.

Στρώμα	Τεχνολογία	Ρόλος
Ingestion	pymupdf4llm	PDF to Markdown (headers, tables)
Chunking	tiktoken (cl100k_base)	Token counting για FixedSize chunker
Indexing	Qdrant	Βάση διανυσμάτων, 3 collections (v1/v2/v3)
Embeddings	text-embedding-3-small (OpenAI)	1536-dim dense vectors
Reranking	BAAI/bge-reranker-base	Cross-encoder, 102M params, CPU
Agent	LangGraph StateGraph	DAG: Planner, Researcher, Synthesizer
LLM	gpt-4.1-mini	Planner, Synthesizer, RAGAS/HAIC judge
UI	Chainlit	Streaming chat, profile selector, HAIC buttons
Tracing	Langfuse (self-hosted)	LLM call tracking, latency, tokens
Cache	SQLite	SHA-256 keyed: embeddings, judge calls, ArXiv

3.3 Demo Screenshots



Εικ. 1: Profile selector, επιλογή μεταξύ v1, v2, v3 chunking strategies.



#1 ORAG: Graph Retrieval-Augmented Generation

From Local to Global: A Graph RAG Approach to Query-Focused Summarization

Darren Edge, Ha Trinh — 2024 — E.2 Community Summary Generation • score: 8.888

Raw code

---Role---

Raw code

You are an AI assistant that helps a human analyst to perform general information discovery. Information discovery is the process of identifying and assessing relevant information associated with certain entities (e.g., organizations and individuals) within a network.

21

Raw code

---Goal---

Raw code

Write a comprehensive report of a community, given a list of entities that belong to the community as well as their relationships and optional associated claims. The report will be used to inform decision-makers about information associated with the community and their potential impact. The content of this report includes an overview of the community's key entities, their legal compliance, technical capabilities, reputation, and noteworthy claims.

Raw code

---Report Structure---

Raw code

The report should include the following sections:

Raw code

- TITLE: community's name that represents its key entities - titles should be short but specific. When possible, include representative named entities in the title.
- SUMMARY: An executive summary of the community's overall structure, how its entities are related to each other, and its significant information associated with its entities.
- IMPACT SEVERITY RATING: A float score between 0-10 that represents the severity of IMPACT posed by entities within the community. IMPACT is the score divided by 10.
[arXiv >] (https://arxiv.org/abs/2404.16130)

On the Brittle Foundations of ReAct Prompting for Agentic Large Language Models

Mudit Verma, Siddhant Bhamri — 2024 — 5 Results • score: 8.815

In the following sub-sections, we will answer our RQs through sensitivity analysis using the proposed prompt variations along three dimensions, the location of the think tag, the content of the think tag,

6

⇒ picture [396 × 148] intentionally omitted ⇐

----- Start of picture text -----

GPT 3.5 Turbo GPT 3.5 Instruct GPT 4 Claude Opus
100 Put 100 Put 100 Put 100 Put
PutTwo 75 CleanPutTwo 75 CleanPutTwo 75 Clean
50 50 50 50
25 25 25 25
0 0 0 0
Cool
Cool Cool Cool

End of picture text -----

Figure 3: The radar chart shows the failure rates of various LLMs with different ReAct-based prompt settings for RQ1 (Base ReAct, Global, Anonymized) across six AIfworld tasks (hexagon vertices). Higher values / Larger shaded region indicate worse performance.

⇒ picture [396 × 131] intentionally omitted ⇐

----- Start of picture text -----

GPT 3.5 Turbo GPT 3.5 Instruct GPT 4 Claude Opus
100 Put 100 Put 100 Put 100 Put
PutTwo 75 CleanPutTwo 75 CleanPutTwo 75 Clean
50 50 50 50
25 25 25 25
0 0 0 0
Cool
Cool Cool Cool

End of picture text -----

arXiv >

ORAG: Graph Retrieval-Augmented Generation


Yuntong Hu, Zhihan Lei — 2024 — A.3 Implementation • score: 8.543

The data splits for training, validation, and test sets are 60%/20%/20% for ExplanatoryGraphs and 60%/5%/35% for WebQSP. All experiments are performed on a Linux-based server with 4 NVIDIA A100 GPUs. We use SentenceBert (Reimers and Gurevych, 2019) to encode the question and text attributes to obtain vectors for the retrieval process. The graph encoder, i.e. GAT (Veličković et al., 2018), has 4 layers with 4 heads per layer and a hidden dimension size of 1024.

The LLM backbone is Llama-2-7b-hf, while the model used is in the setting of LLM only is Llama-2-7b-chat-hf. We employ Lowrank Adaptation (LoRA) (Hu et al., 2021) for finetuning, configuring the LoRA parameters as follows: the dimension of the low-rank matrices is set to 8; the scaling factor is 16; and the dropout rate is 0.05. For the optimization, AdamW optimizer (Loshchilov and Hutter, 2018) is used. The initial learning rate is set to 1e-5 and the weight decay is 0.05. Each experiment runs for up to 10 epochs, and the batch size is 2. For compared retrievers, each experiment on ExplanatoryGraphs is replicated three times, utilizing different retrieval settings for each run, i.e., top-3, top-5 and top-10; Each experiment on WebQSP

arXiv >

Εικ. 2: Streaming UI, αποτελέσματα ανάκτησης και παραγωγή απάντησης σε πραγματικό χρόνο.



Εικ. 3: OpenAI API cost dashboard (Langfuse), παρακολούθηση κόστους ανά session.



4. Στρατηγικές Τεμαχισμού (Chunking)

Ο τεμαχισμός (chunking) είναι κρίσιμο βήμα για την ποιότητα του RAG. Μικρά chunks δίνουν ακριβή precision αλλά χαμηλό recall, ενώ μεγάλα chunks διατηρούν περισσότερο context αλλά μπορεί να εισάγουν θόρυβο. Αναπτύχθηκαν τρεις στρατηγικές για σύγκριση.

4.1 v1: FixedSize Chunker (512 tokens)

Η απλούστερη στρατηγική: το κείμενο κάθε άρθρου τεμαχίζεται σε chunks σταθερού μεγέθους 512 tokens με overlap 50 tokens. Χρησιμοποιείται το cl100k_base encoding (tiktoken). Κάθε chunk αποθηκεύεται στη συλλογή papers_v1 του Qdrant με metadata: paper_id, section_type, start_token, end_token.

Πλεονεκτήματα: απλή υλοποίηση, προβλέψιμο μέγεθος. Μειονεκτήματα: κόβει μέσα σε παραγράφους και πίνακες, αγνοεί τη δομή του άρθρου.

4.2 v2: SectionAware Chunker

Ο δεύτερος chunker αναγνωρίζει επικεφαλίδες Markdown (# ## ### ####) που παράγει το pymupdf4llm και τεμαχίζει κατά ενότητα. Κάθε ενότητα ταξινομείται αυτόματα σε τύπο (abstract, introduction, method, results, conclusion, κ.λπ.) μέσω regex patterns. Αν μια ενότητα υπερβαίνει τα 512 tokens τεμαχίζεται δευτερευόντως με overlap.

Πλεονεκτήματα: σέβεται τη δομή του άρθρου, παράγει semantically συνεκτικά chunks. Μειονεκτήματα: εξαρτάται από την ποιότητα του Markdown output (κάποια PDF δεν έχουν headers).

4.3 v3: TableAware Chunker

Το v3 επεκτείνει το v2 με ειδική διαχείριση Markdown πινάκων. Οι πίνακες δεν κόβονται στη μέση: το chunker εντοπίζει αρχή και τέλος πίνακα (γραμμές με |) και τους διατηρεί ακέραιους. Αυτό βελτιώνει την ανάκτηση για ερωτήσεις που αναζητούν αριθμητικά δεδομένα από πίνακες αποτελεσμάτων.

Πλεονεκτήματα: βελτιωμένο recall σε numerical ερωτήσεις, καλύτερη context recall. Μειονεκτήματα: μεγαλύτεροι πίνακες μπορεί να εξαντλήσουν το context window.

Πίνακας 3: Σύγκριση τριών στρατηγικών τεμαχισμού.

Ιδιότητα	v1 FixedSize	v2 SectionAware	v3 TableAware
Μέγεθος Chunk	512 tokens	Ποικίλλει (1-512)	Ποικίλλει (1-512+)
Overlap	50 tokens	Ανά ενότητα	Ανά ενότητα
Section Type	Δεν ανιχνεύεται	Ανιχνεύεται	Ανιχνεύεται
Table Handling	Κόβει μέσα	Κόβει μέσα	Διατηρεί ακέραιους
Qdrant Collection	papers_v1	papers_v2	papers_v3



5. Αγεντική Ανάκτηση (Agentic RAG)

Το σύστημα υλοποιεί ένα πολυπρακτορικό pipeline με LangGraph StateGraph. Ο γράφος αποτελείται από τρεις κόμβους: Planner, Researcher, Synthesizer, με άμεση σύνδεση Planner-to-END για out-of-context ερωτήσεις.

5.1 Γράφος LangGraph

Ο γράφος ορίζεται ως StateGraph[AgentState]. Το AgentState περιέχει: user_query, plan (JSON), research_notes (bullet facts), raw_chunks (full dicts), tool_calls (list, για TCA), messages (LangChain history), answer (τελικό string).

```
START
|
v
Planner ----[out_of_context]----> Synthesizer
|
v
Researcher (asyncio.gather: rag_retrieve + arxiv_search)
|
v
Synthesizer
|
v
END
```

5.2 Planner

Ο Planner χρησιμοποιεί το gpt-4.1-mini με structured output (Pydantic SearchPlan). Ταξινομεί κάθε ερώτηση σε mode: quick_qa, deep_analysis ή out_of_context. Για deep_analysis παράγει sub_queries[] (IRCoT-style) για multi-hop ανάκτηση. Για out_of_context παρακάμπτει τον Researcher και παράγει απευθείας decline-message μέσω του Synthesizer.

5.3 Researcher

Ο Researcher εκτελεί παράλληλα (asyncio.gather) δύο εργαλεία: rag_retrieve (αναζήτηση στο Qdrant) και arxiv_search (live ArXiv API). Τα αποτελέσματα συγχωνεύονται, deduplicated και reranked με cross-encoder. Στη συνέχεια ο Researcher distills τα raw chunks σε συνοπτικές bullet-point σημειώσεις (research_notes) για εξοικονόμηση tokens στον Synthesizer.

5.4 Ανάκτηση και Reranking

Η ανάκτηση (retriever.py) χρησιμοποιεί dense retrieval με cosine similarity στο Qdrant (top-k=20). Στη συνέχεια εφαρμόζεται cross-encoder reranking με το BAAI/bge-reranker-base (102M params, CPU inference). Το reranker βαθμολογεί κάθε (query, chunk) ζεύγος και επιστρέφει τα top-5. Εφαρμόζεται επίσης diversity filtering: max 1 chunk ανά paper_id στα top-k, ώστε να αποφευχθεί η κυριαρχία ενός μόνο άρθρου.

5.5 Synthesizer

Ο Synthesizer λαμβάνει τις research_notes (bullet facts) και παράγει την τελική Markdown απάντηση. Χρησιμοποιεί prompt που επιβάλλει: χρήση μόνο των παρεχόμενων facts, αναφορά πηγών στο τέλος, ειδοποίηση αν η ερώτηση είναι OOC, και αποφυγή hallucination.

5.6 Caching

Το SQLite cache (sqlite_cache.py) χρησιμοποιεί SHA-256 hash ως κλειδί για τρεις τύπους: (α) embeddings (vector lookup), (β) judge calls (RAGAS/HAIC), (γ) ArXiv search results. Η TTL είναι 7 ημέρες. Αυτό μειώνει σημαντικά το κόστος evaluation σε repeated runs.



6. Πλαίσιο Αξιολόγησης

6.1 RAGAS

Το RAGAS (Automated Evaluation of Retrieval Augmented Generation, Es et al. 2023) αξιολογεί ένα RAG pipeline με 4 μετρικές, χωρίς να απαιτεί human ground truth για κάθε απάντηση:

- Context Precision (CP): Το ποσοστό των ανακτηθέντων chunks που είναι πράγματι σχετικά. Αξιολογεί την ακρίβεια της ανάκτησης.
- Context Recall (CR): Τι ποσοστό των απαραίτητων πληροφοριών βρίσκεται στα ανακτηθέντα chunks. Αξιολογεί την πληρότητα.
- Faithfulness (F): Τι ποσοστό των ισχυρισμών στην απάντηση υποστηρίζεται από τα chunks. Μετράει hallucination.
- Answer Relevancy (AR): Πόσο σχετική είναι η απάντηση με την ερώτηση (ανεξαρτήτως context). Αξιολογεί το LLM output.

Όλες οι μετρικές υπολογίζονται αυτόματα με LLM judge (gpt-4.1-mini) και κυμαίνονται στο [0, 1].

6.2 TCA (Tool Call Accuracy)

Το TCA αξιολογεί αν ο agent επιλέγει τα σωστά εργαλεία για κάθε ερώτηση. Βαθμολογία: 1.0 αν το σύνολο εργαλείων περιλαμβάνει τα expected, 0.5 αν εκτελεστεί κάποιο αλλά όχι όλα, 0.0 αν δεν εκτελεστεί κανένα. Υλοποιείται στο eval/tool_call_acc.py.

6.3 HAIC (Human-AI Collaboration Benchmarking)

Το HAIC αξιολογεί την ποιότητα της συνεργασίας χρήστη-AI από anthropocentric σκοπιά. Δύο formats χρησιμοποιήθηκαν:

- v1 (n=45): 4 μετρικές 1-5/1-3: Helpfulness (1-5), Trust Calibration (1-3), Effort Saved (1-5), Harm Potential (1-3). Manual scoring.
- v2/v3 (n=84): LLM-as-judge με gpt-4.1-mini. Κάθε απάντηση βαθμολογείται 1-5 (judge_score) και χαρακτηρίζεται accepted/rejected με βάση threshold=3.0.

Το HAIC v2/v3 περιλαμβάνει επίσης μετρικές: Exploitation Level (EL), Trust Rate (Tr), Hallucination Check Level (HCL), Failure Rate (F), Abandonment Rate (A), Deviation Rate (D) και EfficiencyScore.




7. Αποτελέσματα RAGAS

7.1 Συνολικά Αποτελέσματα (n=84)

Πίνακας 4: Συνολικές μετρικές RAGAS ανά έκδοση (n=84, OOC diluted).

Μετρική	v1	v2	v3	Καλύτερο
Context Precision	0.163	0.190	0.166	v2 (0.190)
Context Recall	0.354	0.363	0.455	v3 (0.455)
Faithfulness	0.306	0.292	0.284	v1 (0.306)
Answer Relevancy	0.477	0.438	0.335	v1 (0.477)

Σημείωση: τα συνολικά averages είναι diluted από τις 59 OOC ερωτήσεις. Το v3 υπερτερεί σε Context Recall (0.455 vs 0.354 v1) χάρη στον table-aware chunker, αλλά παρουσιάζει χαμηλότερο Answer Relevancy λόγω ευρύτερης OOC κάλυψης που οδηγεί σε αποτελέσματα εκτός θέματος.




Γράφημα 1: Συνολικές μετρικές RAGAS για v1/v2/v3 (n=84).

7.2 Context Precision ανά Κατηγορία

Πίνακας 5: Context Precision ανά κατηγορία ερωτήσεων.

Κατηγορία	v1 CP	v2 CP	v3 CP
definitional	0.894	0.922	0.961
comparative	0.500	0.561	0.561
methodological	0.350	0.400	0.400
attribution	0.283	0.483	0.467
numerical	0.300	0.467	0.400
out_of_context	0.035	0.031	0.000




Γράφημα 2: Context Precision ανά κατηγορία, σύγκριση v1/v2/v3.

7.3 Context Recall ανά Κατηγορία

Πίνακας 6: Context Recall ανά κατηγορία ερωτήσεων.

Κατηγορία	v1 CR	v2 CR	v3 CR
definitional	0.800	1.000	1.000
comparative	0.600	0.700	0.700
methodological	0.550	0.600	0.850
attribution	0.200	0.400	0.400
numerical	0.400	0.200	0.000
out_of_context	0.288	0.271	0.397




Γράφημα 3: Context Recall ανά κατηγορία.



7.4 Faithfulness ανά Κατηγορία


Πίνακας 7: Faithfulness ανά κατηγορία ερωτήσεων.

Κατηγορία	v1 F	v2 F	v3 F
definitional	0.905	0.930	0.821
comparative	0.898	0.767	0.707
methodological	0.764	0.881	0.585
attribution	0.600	0.644	0.499
numerical	0.383	0.691	0.625
out_of_context	0.135	0.083	0.128



Γράφημα 4: Faithfulness ανά κατηγορία.

7.5 Heatmap v3



Γράφημα 5: Heatmap μετρικών RAGAS v3 ανά κατηγορία.



Το heatmap αναδεικνύει ξεκάθαρα το pattern: οι in-context κατηγορίες (definitional CP=0.961, CR=1.0) αποδίδουν εξαιρετικά, ενώ η OOC κατηγορία έχει CP=0.0 και CR=0.397.

7.6 Ανάλυση Αποτελεσμάτων

Βασικά ευρήματα ανά κατηγορία:


- Definitional: Σταθερά καλύτερη κατηγορία. v3 επιτυγχάνει CP=0.961, CR=1.0, F=0.821. Σαφείς ορισμοί υπάρχουν στο corpus.
- Comparative: Μέτρια απόδοση. Χρειάζεται context από πολλά άρθρα ταυτόχρονα.
- Numerical: Το v3 βελτιώνει σε τεμαχισμό πινάκων αλλά CR=0.0 (δεν βρίσκονται τα νούμερα στα chunks).
- OOC: Χαμηλά scores σε CP/F λόγω φύσης της κατηγορίας. Αναμενόμενο.

8. Αποτελέσματα Tool Call Accuracy (TCA)

8.1 Συνολικά Αποτελέσματα

Πίνακας 8: Tool Call Accuracy ανά έκδοση και κατηγορία πλαισίου.

Έκδοση	Overall TCA	In-Context	OOC
v1	0.619	1.000	0.458
v2	0.298	1.000	0.000
v3	0.298	1.000	0.000



Γράφημα 6: Tool Call Accuracy ανά κατηγορία για v1/v2/v3.

8.2 Ανάλυση

Για τις in-context κατηγορίες (definitional, comparative, methodological, attribution, numerical) και οι τρεις εκδόσεις επιτυγχάνουν TCA=1.0. Ο Planner ταξινομεί σωστά αυτές τις ερωτήσεις και επιλέγει rag_retrieve.

Για OOC ερωτήσεις: v1 TCA=0.458, v2/v3 TCA=0.0. Το v2/v3 εισήγαγε αυστηρότερο OOC classification στον Planner, με αποτέλεσμα πολλές OOC ερωτήσεις να λαμβάνουν decline-message χωρίς κλήση εργαλείων (actual=[], ενώ expected=[rag_retrieve, arxiv_search]). Αυτό οδηγεί σε TCA=0.0 για OOC, αλλά είναι σωστή συμπεριφορά: το σύστημα δεν πρέπει να αναζητά άσχετο περιεχόμενο. Η παρατηρούμενη πτώση TCA για OOC είναι θέμα ορισμού: το golden set αναμένει κλήση εργαλείων για OOC, αλλά το v2/v3 επιλέγει σωστά να μην καλέσει.



9. Αποτελέσματα HAIC

9.1 HAIC v1 (4 μετρικές, n=45)

Πίνακας 9: HAIC v1 αποτελέσματα (n=45, manual scoring).

Μετρική	Κλίμακα	Score	Ερμηνεία
Helpfulness	1-5	3.76	3.76/5 - Καλή χρησιμότητα
Trust Calibration	1-3	2.82	2.82/3 - Σωστή βεβαιότητα
Effort Saved	1-5	3.31	3.31/5 - Σημαντική εξοικονόμηση
Harm Potential	1-3	1.07	1.07/3 - Ελάχιστος κίνδυνος

Τα v1 αποτελέσματα δείχνουν ικανοποιητική απόδοση: υψηλή χρησιμότητα (3.76/5), σωστή βαθμονόμηση εμπιστοσύνης (2.82/3) και χαμηλό δυνητικό βλάβης (1.07/3). Το n=45 αντιστοιχεί στο αρχικό σύνολο ερωτήσεων πριν την επέκταση σε 84.

9.2 HAIC v2 (LLM Judge, n=84)


Πίνακας 10: HAIC v2 αποτελέσματα ανά κατηγορία (n=84, LLM judge).

Κατηγορία	n	Accept Rate	Mean Judge Score (1-5)
definitional	5	100.0%	4.80
comparative	5	100.0%	3.60
methodological	5	100.0%	3.80
attribution	5	80.0%	3.60
numerical	5	40.0%	2.40
out_of_context	59	30.5%	2.14


9.3 HAIC v3 (LLM Judge, n=84)

Πίνακας 11: HAIC v3 αποτελέσματα ανά κατηγορία (n=84, LLM judge).

Κατηγορία	n	Accept Rate	Mean Judge Score (1-5)
definitional	5	100.0%	4.20
comparative	5	60.0%	2.60
methodological	5	60.0%	3.00
attribution	5	20.0%	1.80
numerical	5	60.0%	3.40
out_of_context	59	86.4%	4.46



Γράφημα 7: Accept Rate ανά κατηγορία (v2/v3).



Γράφημα 8: Mean Judge Score ανά κατηγορία (v2/v3).

9.4 Ανάλυση HAIC

Εντυπωσιακό εύρημα: στο v3 οι OOC ερωτήσεις έχουν `accept_rate=86.4%` και `mean_judge_score=4.46/5`. Αυτό οφείλεται στο ότι το v3 απαντά εκτεταμένα σε OOC ερωτήσεις αντλώντας από τη γνώση του LLM (παρά τη χαμηλή TCA). Ο judge βαθμολογεί υψηλά τις informative απαντήσεις, ακόμα κι αν δεν χρησιμοποιήθηκαν σωστά εργαλεία.

Αντίθετα, οι in-context κατηγορίες στο v3 παρουσιάζουν `accept_rate=60%` και `mean_judge_score=3.0/5`, χαμηλότερα από v2 (definitional=1.0, 4.8). Αυτό υποδηλώνει ότι ο table-aware chunker εισάγει θόρυβο στις απαντήσεις για in-context ερωτήσεις.

Σημαντική διαφορά format v1/v2: τα v1 metrics (Helpfulness/Trust/Effort/Harm) δεν είναι άμεσα συγκρίσιμα με τα v2/v3 (Judge Score/Accept Rate). Η σύγκριση είναι ενδεικτική.



10. Ανάλυση Αποτυχιών

10.1 Κύρια Πρότυπα Αποτυχίας

Από την ανάλυση των 84 ερωτήσεων εντοπίστηκαν τα εξής πρότυπα αποτυχίας:

Χαμηλή Context Precision σε OOC

Το σύστημα ανακτά chunks που δεν σχετίζονται με OOC ερωτήσεις, καθώς το Qdrant δεν μπορεί να επιστρέψει 'καμία απάντηση'. Αυτό μειώνει το global CP. Το v3 έχει OOC CP=0.0 επειδή ο Planner δεν καλεί rag_retrieve για OOC, οπότε δεν υπάρχουν retrieved chunks.

Χαμηλό Numerical Recall

Ερωτήσεις τύπου 'πόσα parameters έχει το BGE-reranker-base' απαιτούν ακριβή αριθμητικά δεδομένα από πίνακες, τα οποία συχνά χάνονται κατά τον τεμαχισμό. Το v3 βελτιώνει αλλά δεν επιλύει πλήρως το πρόβλημα.

Hallucination σε Attribution

Ερωτήσεις τύπου 'ποιος πρότεινε το Self-RAG' οδηγούν σε απαντήσεις βασισμένες στην παραμετρική γνώση του LLM αντί στα retrieved chunks, μειώνοντας το Faithfulness.

OOC Dilution στα Overall Averages

Με 59/84 ερωτήσεις εκτός context (70.2%), τα global RAGAS averages δεν αντικατοπτρίζουν αξιόπιστα την in-context απόδοση. Για πλήρη εικόνα: In-context context_recall v3=0.65 (vs 0.455 overall).

10.2 Σύγκριση Εκδόσεων ανά Πρόβλημα

Πίνακας 12: Σύγκριση εκδόσεων v1/v2/v3 ανά κατηγορία προβλήματος.

Πρόβλημα	v1	v2	v3	Σχόλιο
OOC Tool Selection	Μερική	Αυστηρή	Αυστηρή	v2/v3 decline χωρίς κλήση
Table Preservation	Κόβει	Κόβει	Διατηρεί	v3 βελτιώνει numericals
Section Context	Δεν υπάρχει	Υπάρχει	Υπάρχει	v2/v3 καλύτερο definitional
Answer Quality	Καλή AR=0.477	Μέτρια AR=0.438	Χαμηλή AR=0.335	v3 verbose
Faithfulness	0.306	0.292	0.284	Παρόμοιο, μικρή πτώση



11. Περιορισμοί και Μελλοντική Εργασία

11.1 Τρέχοντες Περιορισμοί

Πίνακας 13: Τρέχοντες περιορισμοί του συστήματος.

Περιορισμός	Επεξήγηση
OOO-diluted overall scores	59/84 OOC ερωτήσεις dilute τα overall RAGAS averages. Χρειάζεται χωριστή αναφορά in-context vs OOC για ολοκληρωμένη εικόνα.
HAIC v1/v2 format ασυμβατότητα	v1: 4 μετρικές (Helpfulness/Trust/Effort/Harm), n=45. v2: ενιαία Judge Score, n=84. Η σύγκριση είναι ενδεικτική.
Anglophone corpus	Μόνο αγγλόφωνα ArXiv papers. Ελληνόφωνες ερωτήσεις δεν δοκιμάστηκαν.
No multi-hop retrieval	O agent δεν αναλύει σύνθετες ερωτήσεις σε υπο-ερωτήματα (decomposition).
HAIC scored by LLM judge	Δεν υπάρχει human baseline για cross-validation των HAIC scores.
ArXiv rate limiting	HTTP 429 κατά eval batch. OOC Tool Call Accuracy επηρεάστηκε.

11.2 Μελλοντικές Βελτιώσεις

Πίνακας 14: Προτεινόμενες μελλοντικές βελτιώσεις.

Βελτίωση	Περιγραφή
Table-aware chunker v2	Διατήρηση Markdown tables ακέραιων για numerical Qs.
Diversity reranking	Max 1 chunk/paper_id στα top-k.
Author alias metadata	Paper nicknames (HyDE, Self-RAG) στο Qdrant payload.
Iterative retrieval	IRCoT-style decomposition πολύπλοκων ερωτήσεων.
Multi-agent orchestration	Orchestrator-worker pattern για parallel retrieval.
Eval ArXiv caching	Cache arxiv search results κατά evaluation για αποφυγή 429.

11.3 Υλοποιηθείσες Βελτιώσεις Ανάπτυξης (Post-v3)

Μετά την ολοκλήρωση της αξιολόγησης v3, υλοποιήθηκαν τέσσερις επιπλέον βελτιώσεις που αφορούν την ανθεκτικότητα, τη χρηστικότητα και τη συνέχεια της διεπαφής χρήστη στο περιβάλλον ανάπτυξης Docker/Chainlit.

Επιμονή Ιστορικού Συνομιλιών (Thread Persistence)

Υλοποιήθηκε επίμονο στρώμα δεδομένων για το Chainlit μέσω της κλάσης SQLAlchemyDataLayer σε συνδυασμό με ασύγχρονη SQLite βάση δεδομένων (aiosqlite). Η βάση αποθηκεύεται σε Docker named volume (chainlit_db) στο Linux filesystem του container, αποφεύγοντας ζητήματα κλειδώματος αρχείων που εμφανίζονται σε NTFS Windows bind mounts. Το σχήμα δημιουργείται αυτόματα κατά την εκκίνηση. Χάρη σε αυτή τη βελτίωση, το ιστορικό συνομιλιών διατηρείται ακόμη και μετά από κλείσιμο του browser ή επανεκκίνηση του container, και εμφανίζεται στην αριστερή πλευρική μπάρα του Chainlit.

Μεταφόρτωση PDF και In-Session RAG

Ενεργοποιήθηκε η δυνατότητα μεταφόρτωσης αρχείων PDF από τον χρήστη απευθείας μέσα στη συνομιλία (spontaneous_file_upload, αρχεία έως 50 MB). Κάθε ανεβασμένο έγγραφο τεμαχίζεται μέσω ολισθαίνοντος παραθύρου (512 tokens, 50-token overlap) με χρήση του tokenizer cl100k_base (tiktoken), ενσωματώνεται μέσω του EmbeddingProvider και αποθηκεύεται προσωρινά στη session μνήμη. Κατά τη διατύπωση ερώτησης, τα session chunks αναζητώνται παράλληλα με το κύριο corpus Qdrant. Στο interface εμφανίζεται κουμπί «Clear uploads» που αφαιρεί τα προσωρινά chunks από τη session.

In-Chat Εναλλαγή Εκδόσεων v1 / v2 / v3

Στο κάτω μέρος κάθε απάντησης εμφανίζονται κουμπιά ενεργειών [v1], [v2], [v3] που επιτρέπουν την εναλλαγή μεταξύ των εκδόσεων του pipeline χωρίς επαναφόρτωση της σελίδας ή δημιουργία νέου thread. Το ιστορικό της



συνομιλίας διατηρείται ακόμη και μετά την εναλλαγή, επιτρέποντας στον χρήστη να συγκρίνει απαντήσεις του ίδιου ερωτήματος μεταξύ v1, v2 και v3 μέσα στο ίδιο session.

Επιπλέον Τεχνικές Βελτιώσεις

Caching μοντέλου reranker: Η μεταβλητή HF_HOME ρυθμίστηκε ώστε να δείχνει στον bind-mounted κατάλογο /app/data/hf_cache, με αποτέλεσμα το μοντέλο BAAI/bge-reranker-base (~280 MB) να κατεβαίνει μόνο μία φορά και να παραμένει διαθέσιμο σε κάθε επόμενη εκκίνηση του container. Σε περίπτωση μη διαθεσιμότητας του μοντέλου, τα pipelines v2 και v3 επιστρέφουν gracefully τα αποτελέσματα με βάση το dense score. Επιπλέον, το σύστημα παρακολούθησης ενημερώθηκε για συμβατότητα με Langfuse 4.7.1, όπου ο CallbackHandler για LangChain εισάγεται πλέον από το langfuse.langchain.

12. Συμπεράσματα

Το PaperPilot υλοποιεί ένα ολοκληρωμένο σύστημα αμεσικής ανάκτησης για ακαδημαϊκά άρθρα, με αξιολόγηση σε τρία επίπεδα (RAGAS, TCA, HAIC). Τα κύρια ευρήματα:

- Η SectionAware στρατηγική (v2) βελτιώνει Context Precision σε σχέση με FixedSize (0.190 vs 0.163), αλλά όχι δραματικά.
- Η TableAware στρατηγική (v3) βελτιώνει Context Recall (0.455 vs 0.354 v1) αλλά μειώνει Answer Relevancy λόγω verbose απαντήσεων.
- Για in-context ερωτήσεις το σύστημα αποδίδει καλά: definitional CP=0.961, CR=1.0 (v3), TCA=1.0 (όλες εκδόσεις).
- Το OOC dilution (70.2% OOC) είναι ο κύριος παράγοντας για τα χαμηλά global averages και πρέπει να λαμβάνεται υπόψη κατά την ερμηνεία.
- Το HAIC δείχνει υψηλή αποδοχή για OOC ερωτήσεις (v3: 86.4%), καθώς ο judge εκτιμά τις informative decline-messages.
- Η αρχιτεκτονία LangGraph είναι επεκτάσιμη: νέα εργαλεία, νέοι κόμβοι και νέες στρατηγικές chunking μπορούν να προστεθούν χωρίς αλλαγή στο pipeline.

Συνολικά, το PaperPilot αποτελεί μια ολοκληρωμένη proof-of-concept εφαρμογή RAG με πλήρες evaluation framework που καλύπτει retrieval, agent behavior και human-centered metrics.